

Opis problemu i metody – Kategoryzator Wydatków

Maciej Grzywacz

1. Opis problemu

Automatyczna klasyfikacja transakcji bankowych na kategorie: Jedzenie, Transport, Rozrywka, Rachunki. Celem jest ułatwienie analizy wydatków i budżetowania domowego.

Zastosowanie praktyczne:

Automatyczne budżetowanie domowe, integracja z aplikacjami bankowymi (Millennium, mBank, PKO), wspomaganie analizy wydatków bez ręcznego oznaczania każdej transakcji.

2. Opis danych

Zbiór 50 transakcji w formacie CSV:

Opis	Kwota	Kategoria
Biedronka zakupy	45.50	Jedzenie
MPK bilet	98.00	Transport
Netflix abonament	29.90	Rozrywka
Energa prąd	245.00	Rachunki

Cechy: kwota, długość opisu, słowa kluczowe (biedronka, mpk, netflix itp.), kategoria kwoty (niska/średnia/wysoka).

3. Uzasadnienie wyboru algorytmu

Wybrano drzewo decyzyjne ID3 z powodów:

- Interpretowalność – łatwe do wyjaśnienia
- Brak potrzeby normalizacji danych
- Prostota implementacji od podstaw
- Zgodność z wymaganiami (brak gotowych bibliotek ML)

4. Wyjaśnienie działania metody

Drzewo decyzyjne budowane jest rekurencyjnie:

1. Entropia – mierzy niepewność zbioru: $H(S) = -\sum p_i \cdot \log_2(p_i)$
2. Przyrost informacji – wybór najlepszej cechy do podziału: $IG(S,A) = H(S) - \sum (|S_v|/|S|) \cdot H(S_v)$
3. Budowa – wybierz cechę z największym IG, podziel zbiór, powtarzaj

Przykład:

Czy opis zawiera "netflix"?

TAK -> Rozrywka

NIE -> Czy kwota < 20 zł?

TAK -> Jedzenie

NIE -> Transport lub Rachunki